

SIALOCK

T24 — GRUPO 3

Documentação Técnica Completa e Relatório Metodológico

Sistema de Inteligência, Reconciliação, Análise de Risco e Predição de CNPJ
(Versão V.3.3 — Gate 3 / Processamento Incremental em Lotes)

1. COMPONENTE 2: RELATÓRIO DE DESENVOLVIMENTO DA METODOLOGIA

1.1 Introdução e Contexto do Desafio

O SIALOCK é um sistema de inteligência de dados projetado para resolver a reconciliação e reidentificação de entidades empresariais no comércio exterior brasileiro [cite: 5]. Na etapa do Gate 3 (Versão V.3.3), a arquitetura foi aprimorada para processar de maneira eficiente e incremental grandes volumes de dados (23+ milhões de registros das Bases 2 e 3 da Receita Federal do Brasil - RFB), mantendo isolamento absoluto entre as bases e tolerância total a falhas [cite: 2, 6].


1.2 Regras de Preenchimento e Validação dos Palpites (Componente 1)


O pipeline do SIALOCK garante o cumprimento estrito de todas as regras do Regulamento Oficial (Item 7.3) [cite: 6]:

- **Limite de Palpites:** Apenas os 50 melhores palpites por base foram selecionados para compor as entregas finais (ENTREGA_base2.xlsx e ENTREGA_base3.xlsx) [cite: 2, 6].
- **Formatação de CNPJ:** Todos os CNPJs foram normalizados para exatamente 14 dígitos numéricos (sem traços, pontos ou caracteres especiais) [cite: 2, 6].
- **Unicidade de CNPJ:** O sistema aplica um filtro estrito para impedir a indicação repetida de um mesmo CNPJ dentro da mesma base e entre as bases distintas (Bases 1, 2 e 3) [cite: 6].
- **Validação Algorítmica:** Validação oficial dos dígitos verificadores (DV1 e DV2) do CNPJ antes da inclusão nos palpites finais [cite: 2].

1.3 Arquitetura de Processamento Incremental (Gate 3 — V.3.3)

Para viabilizar o processamento de mais de 23 milhões de linhas em qualquer infraestrutura sem estouro de memória RAM, o SIALOCK foi estruturado em lotes (*batches*) [cite: 2, 6]:





1.4 Módulo de Otimização de Recursos (rapidez.py)

- **Ajuste Dinâmico de Lotes (*Batch Size*):** O sistema monitora o consumo de RAM via `psutil` e adapta dinamicamente o tamanho do lote para evitar degradação de desempenho.
- **Redução de Memória (*Downcasting*):** Tipos numéricos e categóricos do Pandas são convertidos para representações de menor pegada em memória [cite: 3].
- **Execução Paralela:** Uso de *pools* de processos e *threads* com desativação automática em ambientes de baixa capacidade [cite: 3].

1.5 Mecanismo de Recuperação e Tolerância a Falhas (Checkpointing)

O progresso da execução de cada base é registrado em tempo real no arquivo `progresso.json` [cite: 2]. Em caso de desconexão ou interrupção, a reexecução retoma a leitura exatamente do último lote processado, sem duplicação de processamento ou contaminação dos dados [cite: 2].

1.6 Fontes Externas e Economia de Requisições

O SIALOCK faz uso exclusivo de fontes públicas e legais (BrasilAPI, Minha Receita, ReceitaWS, CNPJWS) [cite: 1, 5, 6]. Para cumprir o critério de **Economia de Fontes** (Critério Secundário 4) [cite: 6]:

- Os resultados das consultas são armazenados em um cache local unificado (`./cache_externo/cnpj_cache.parquet`) [cite: 1, 5].
- Consultas subsequentes leem primeiro o cache em disco, zerando requisições repetidas de rede e garantindo estabilidade no processamento [cite: 1, 5].

2. COMPONENTE 3: PLANO DE MITIGAÇÃO DE RISCO DE EXPOSIÇÃO E SEGURANÇA DOS DADOS

2.1 Diagnóstico de Vulnerabilidade e Risco de Reidentificação

A partir dos testes de reidentificação conduzidos no Exercício Técnico, o SIALOCK identificou que a combinação de campos granulares (como NCM/HS-Code, país de origem, peso líquido e valor das operações VMLE em dólar) pode criar "assinaturas operacionais únicas", permitindo inferir o CNPJ responsável mesmo na ausência do nome da empresa [cite: 5, 6].

2.2 Proposta de Mitigação

Para mitigar o risco de exposição mantendo a utilidade analítica das bases para defesa comercial, propõe-se uma estratégia baseada em três pilares [cite: 6]:

1. **Generalização Hierárquica de NCM/HS-Code:** Agrupar os códigos NCM nos níveis de posição (4 dígitos) ou subposição (6 dígitos) para operações de alto risco de reidentificação.
2. **Microagregação e Adição de Ruído Controlado (Laplace/Gaussiano):** Aplicação de ruído estatístico de valor insignificante aos campos contínuos (`peso_liquido` e `vmle_dolar`), eliminando valores exatos que coincidam com registros de notas fiscais ou manifesto de carga.
3. **Mapeamento de K-Anonymity Dinâmico:** Garantir que qualquer combinação de variáveis de uma operação seja compartilhada por pelo menos K empresas na base tratada antes da disponibilização pública.

2.3 Avaliação do Impacto na Utilidade Analítica

- **Análises Mantidas (Utilidade Preservada):** Estudos setoriais de defesa comercial, acompanhamento de volume por país de origem e tendências agregadas por capítulo/posição do NCM permanecem totalmente viáveis [cite: 6].
- **Limitações Introduzidas:** Impossibilidade de auditoria pontual de transações individuais de uma única empresa, exatamente o objetivo exigido para a proteção do sigilo fiscal (Portaria RFB nº 100/2021) [cite: 6].

2.4 Nível de Maturidade da Proposta

- **Nível 2 — Protótipo Validado em Amostra:** A solução de mitigação possui rotinas implementadas e testadas sobre as amostras do Exercício (calculando `RiskScore` e `KPI_Outlier` para identificar a vulnerabilidade e validar a redução do risco) [cite: 1, 2, 6].

3. ESTRUTURA DE DIRETÓRIOS E ENTREGA

```
gate3/
├── extract_v.3.3.py      # Script principal da pipeline
├── rapidez.py           # Módulo de otimização de memória e performance
├── base2/
│   ├── entrada/        # Base 2 bruta de entrada
│   ├── palpites/       # Arquivos de palpites por lote (palpite0.xlsx, ...)
│   ├── modelos/        # Modelo persistido (modelo_gate3_base2.joblib)
│   ├── progresso.json  # Checkpoint de recuperação
│   └── ENTREGA_base2.xlsx # Planilha de submissão da Base 2 (Componente 1)
├── base3/
│   ├── entrada/
│   ├── palpites/
│   ├── modelos/
│   ├── progresso.json
│   └── ENTREGA_base3.xlsx # Planilha de submissão da Base 3 (Componente 1)
```

4. TECNOLOGIAS E DEPENDÊNCIAS

- **Linguagem:** Python 3.10+ [cite: 3]
- **Processamento & ML:** Pandas, NumPy, Scikit-Learn (`SGDClassifier`, `PassiveAggressiveClassifier`, `ComplementNB`, `LinearSVC`)
- **Otimização & Sistema:** `psutil`, `joblib`, `multiprocessing`, `concurrent.futures`
- **Armazenamento & Exportação:** PyArrow (Parquet), OpenPyXL (Excel)